

EvidenceGap-V pilot：造 5 条"粗看分不清、拿到证据才可判"的视频孪生样本，并用 DeepEyes-7B 走完认证

2026-09-04 · 数据与代码：[data/evidencegap_v_pilot/](#) · 本文由 `make_report.py` 从已执行的 notebook 自动排版

0. 一句话结论


五条受控编辑的孪生样本在中英文下都通过了 C1–C4 认证：8 帧粗采样下 A/B 的答案信念几乎相同、配对平均 $p(y^*)$ 在 chance 附近；追加真证据后 $p(y^*) \geq 0.65$ （多数 ≥ 0.99 ）；换成孪生视频的证据后答案跟着翻；文本本身没有捷径。同一批样本上，DeepEyes-7B 自己用 zoom+seek 工具只对 2–4/10，每对孪生最多对一边——不比按先验猜好。它的中文推理轨迹把三层失败写得很直白：粗采样里没有的东西它"看到了"，seek 到错误时间段后照样宣称"更清晰地看到了"，最后按语言先验作答。

1. 做了什么

目的不是训练数据，而是把方案（PROPOSAL_evidence_acquisition_260904.md §3–§4）里"Evidence Necessity 由样本客观决定、用成对样本 + 四种证据条件来测"这一套，先在 3–5 条样本上跑通：造样本 → DeepEyes 认证 → 迭代到它"确实改不动"。样本全部是在 VideoNet 真实视频上做最小合成编辑（方案里的来源 B），每条带一个孪生版本 A/B：粗观测下两者不可区分，答案不同，差异只在 E^* （时间窗 × 空间框）里。

样本	机制	底片	孪生差异	E^*	定版
s1_occlusion_color	遮挡解除（时间为主）	f103252e 咖啡俯拍 18s	卡片下圆片 红/蓝	帧 262–292（两个粗采样点之间）× 卡片区域	v1
s2_tiny_tag	局部小字（空间为主）	905ce3c1 调酒 4s	标签数字 358/386，字高 9px	全程 × 44×30 px	v4
s2b_tiny_tag_1080p	同上，1080p 底片	f103252e	字高 12px	全程 × 56×38 px	v4
s3_roll_direction	短时窗动作 + 时序	1c47ea6a 咖啡俯拍 9s	小球 朝右/朝左	帧 160–187 × 桌面底部横条	v2
s3b_flash_symbol	短时窗一闪而过的物体	1c47ea6a	卡片符号 三角形/圆形	帧 160–187 × 卡片区域	v3

粗观测 = 8 帧均匀采样、每帧 $\leq 256 \cdot 28^2$ 像素（与 07-23 探针和 VideoNet 评测协议一致）。S1/S3/S3b 的证据窗口严格落在两个粗采样点之间，8 帧下根本采不到；S2/S2b 的标签全程在画面里，但缩放后只有 ~ 4 px 高。下图每行左 8 张是模型在粗观测下实际看到的帧，右 2 张是 E^* 证据帧。



四种证据条件与判据

同一粗观测前缀，只换追加给模型的"工具返回帧"：true = 本视频 E* 窗口内 4 帧裁到 E* 框（高分辨率）；twin = 孪生视频同窗口同框的 4 帧，忠实用证据的模型应翻到孪生答案；decoy = 同框同尺寸但不含判别信息（窗口外的帧 / 另一块台面），不应产生错误确信；irr = 同尺寸灰图；另有 text（无帧）和 none_k8/16/32（不同预算的均匀采样）。信念 b = 四个选项字母首 token 的 softmax，对选项顺序做 4 个循环置换取平均（去字母偏置，judge-free）。

条件	判据
C1 粗观测不可辨	A/B 在 none_k8 下信念的 TV 距离 < 0.15，且孪生对平均 $p(y^*) \leq 0.6$
C2 证据充分	true 下 A/B 都答对且 $p(y^*) \geq 0.6$
C3 无文本捷径	text 下同 C1
C4 证据可交换	twin 下 A/B 都翻到孪生答案且 $p \geq 0.6$
附加（不进 PASS）	decoy 不产生错误确信；irr 相对 none 的 TV < 0.25 —— 这是对模型的测量，不是样本缺陷

C1/C3 用配对平均而不是"每一边都 < 0.5"：模型对某个选项有语言先验（"朝右侧" 0.80）时单边必然高，但配对平均仍在 chance——那是要测量的 over-confidence，单独报成 prior_bias。

2. 迭代过程：改到 DeepEyes 确实改不动

版本	改动	结果
v1 初版三条		S1 ✓；S2 ✗C1（24px 字在粗采样下 ~11px，p=0.99 直接读出）；S3 全挂（"from left to right" 文本先验 0.82，真证据也推不出方向）
v2 S2 字 15px；S3 球放大、证据框加高、选项改对称措辞；新增 S3b 符号卡		S2 仍 ✗（~7px 仍可读）；S3 C2/C4 过了但先验单边 > 0.5；S3b 只挂 C3（"cross" 先验 0.52）
v3 判据改为孪生对平均；S2 字 12px；新增 S2b（1080p 底片 15px）；S3b 换 circle		S3 ✓、S3b ✓；S2 ✗（~5.5px 仍 0.99）；S2b ✗（~4.7px 半可读：A 0.87，B 误读）
v4 S2 字 9px（~4.1px）；S2b 字 12px（~3.7px）		全部 ✓

迭代里学到的一个具体数字：DeepEyes-7B 在 588x336 的粗采样帧上能可靠读出 ~5.5px 高的粗体数字，要到 ~4px 才真读不出；而原生 9–12px 的裁剪它 100% 读对。下图是 v3 时模型看到的粗采样标签（上两行 720p/12px，下两行 1080p/15px，放大 8 倍）——上两行人眼也能认，所以 DeepEyes 读出来不奇怪。



3. 认证结果

英文版 (eval/results_final.json) :

样本	C1	C2	C3	C4	none_k8 配对 p(y*)	true p(y*) A/B	twin 翻转 A/B	agentic A/B
s1_occlusion_color	✓	✓	✓	✓	0.35	1.00/0.99	1.00/1.00	✓x
s2_tiny_tag	✓	✓	✓	✓	0.29	1.00/1.00	1.00/1.00	xx
s2b_tiny_tag_1080p	✓	✓	✓	✓	0.21	1.00/1.00	1.00/1.00	✓x
s3b_flash_symbol	✓	✓	✓	✓	0.33	1.00/1.00	1.00/1.00	x✓
s3_roll_direction	✓	✓	✓	✓	0.47	0.95/0.72	0.72/0.95	✓x

中文版 (题面、选项、提示词全中文并要求模型用中文思考; eval/results_notebook.json) :

样本	C1	C2	C3	C4	none_k8 配对 p(y*)	true p(y*) A/B	twin 翻转 A/B	decoy 无错误确信	文本先验偏置
s1_occlusion_color	✓	✓	✓	✓	0.32	0.99/0.99	0.99/0.99	x	0.06
s2_tiny_tag	✓	✓	✓	✓	0.25	1.00/1.00	1.00/1.00	✓	0.12
s2b_tiny_tag_1080p	✓	✓	✓	✓	0.25	1.00/1.00	1.00/1.00	✓	0.13
s3b_flash_symbol	✓	✓	✓	✓	0.23	1.00/0.99	0.99/1.00	✓	0.09
s3_roll_direction	✓	✓	✓	✓	0.48	0.75/0.63	0.62/0.75	✓	0.67

读法: none_k8 下 A/B 信念几乎相同 (TV ≤ 0.04) , 配对平均在 chance → 粗观测客观分不开; true 下 p(y*) 全部 ≥ 0.65、twin 下全部翻到孪生答案 → 答案由证据内容决定。none_k16/32 在 S1/S3/S3b 上能解 (窗口被采到) , 在 S2/S2b 上仍不能 (分辨率问题加帧没用) ——正是方案里说的 necessity 随观测预算变化的曲线。中文下 s1 在 decoy (只看到卡片的裁剪) 下对"红色"的置信从 0.44 涨到 0.59, 是 False Resolution 的雏形, 英文下没出现。


无工具直接推理 正确: 3/10 | 带工具主动推理 正确: 2/10

4. 六个证据条件下的信念 (中文版, 每条样本一张信念表 + 一张柱状图)


信念表: 绿色列 = 该孪生的正确答案, pred 标红 = 答错; 柱状图: 绿柱 = p(本视频的正确答案), 橙柱 = p(孪生视频的答案), 虚线 = 0.25。要看的形状: none 下 A/B 两行几乎一样且在 chance 附近; true 下绿柱接近 1; twin 下橙柱接近 1; decoy/irr 回到 none 的形状。

s1_occlusion_color

问题: 画面左下方的台面上有一个小圆形物体, 视频里大部分时间它都被一张深色卡片盖着, 只有很短的一瞬卡片滑开、物体露了出来。这个圆形物体是什么颜色? A. 红色 B. 蓝色 C. 绿色 D. 黄色



		红色	蓝色	绿色	黄色	pred	p_gt	p_twin
twin	cond							
A	text	0.36	0.30	0.11	0.23	红色	0.36	0.30
none		0.42	0.22	0.09	0.27	红色	0.42	0.22
true		0.99	0.00	0.00	0.00	红色	0.99	0.00
twin		0.00	0.99	0.00	0.00	蓝色	0.00	0.99
decoy		0.58	0.15	0.07	0.21	红色	0.58	0.15
irr		0.53	0.16	0.07	0.24	红色	0.53	0.16
B	text	0.36	0.30	0.11	0.23	红色	0.30	0.36
none		0.43	0.21	0.09	0.27	红色	0.21	0.43
true		0.00	0.99	0.00	0.00	蓝色	0.99	0.00
twin		0.99	0.00	0.00	0.00	红色	0.00	0.99
decoy		0.59	0.13	0.07	0.21	红色	0.13	0.59
irr		0.53	0.16	0.07	0.23	红色	0.16	0.53




s2_tiny_tag

问题：画面右下方的吧台上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？ A. 358 B. 356 C. 338 D. 386




		358	356	338	386	pred	p_gt	p_twin
twin	cond							
A	text	0.32	0.22	0.26	0.20	356	0.32	0.20
none		0.27	0.33	0.21	0.18	356	0.27	0.18
true		1.00	0.00	0.00	0.00	358	1.00	0.00
twin		0.00	0.00	0.00	1.00	386	0.00	1.00
decoy		0.27	0.34	0.21	0.18	356	0.27	0.18
irr		0.27	0.33	0.22	0.19	356	0.27	0.19
B	text	0.32	0.22	0.26	0.20	356	0.20	0.32
none		0.27	0.29	0.22	0.22	356	0.22	0.27

true	0.00	0.00	0.00	1.00	386	1.00	0.00
twin	1.00	0.00	0.00	0.00	358	0.00	1.00
decoy	0.28	0.32	0.21	0.19	356	0.19	0.28
irr	0.27	0.31	0.22	0.20	356	0.20	0.27




s2b_tiny_tag_1080p

问题：画面底部中央的台面上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？ A. 358 B. 356 C. 338 D. 386




		358	356	338	386	pred	p_gt	p_twin
twin	cond							
A	text	0.33	0.25	0.23	0.20	356	0.33	0.20
none		0.28	0.35	0.17	0.20	358	0.28	0.20
true		1.00	0.00	0.00	0.00	358	1.00	0.00
twin		0.00	0.00	0.00	1.00	386	0.00	1.00
decoy		0.30	0.33	0.18	0.18	358	0.30	0.18
irr		0.30	0.33	0.19	0.18	358	0.30	0.18
B	text	0.33	0.25	0.23	0.20	356	0.20	0.33
none		0.26	0.38	0.15	0.21	358	0.21	0.26
true		0.00	0.00	0.00	1.00	386	1.00	0.00
twin		1.00	0.00	0.00	0.00	358	0.00	1.00
decoy		0.28	0.38	0.17	0.18	356	0.18	0.28
irr		0.27	0.37	0.18	0.18	356	0.18	0.27




s3b_flash_symbol

问题：视频中有一瞬间，画面右下方的桌面上出现一张印着黑色图案的白色卡片。卡片上的图案是什么？ A. 三角形 B. 正方形 C. 圆形 D. 十字




		三角形	正方形	圆形	十字	pred	p_gt	p_twin
twin	cond							
A	text	0.10	0.07	0.19	0.64	十字	0.10	0.19
	none	0.11	0.07	0.34	0.48	圆形	0.11	0.34
	true	1.00	0.00	0.00	0.00	三角形	1.00	0.00
	twin	0.00	0.01	0.99	0.00	圆形	0.00	0.99
	decoy	0.13	0.07	0.29	0.50	十字	0.13	0.29
	irr	0.11	0.08	0.33	0.49	十字	0.11	0.33
B	text	0.10	0.07	0.19	0.64	十字	0.19	0.10
	none	0.12	0.07	0.34	0.47	圆形	0.34	0.12
	true	0.00	0.01	0.99	0.00	圆形	0.99	0.00
	twin	1.00	0.00	0.00	0.00	三角形	0.00	1.00
	decoy	0.14	0.07	0.28	0.50	十字	0.28	0.14
	irr	0.11	0.07	0.33	0.48	十字	0.33	0.11




s3_roll_direction

问题：视频中有一瞬间，一个橙色小球从画面底部的桌面上滚过。随着时间推移，小球朝画面的哪一侧运动？ A. 朝右侧 B. 朝左侧 C. 朝上方 D. 朝下方





		朝右侧	朝左侧	朝上方	朝下方	pred	p_gt	p_twin
twin	cond							
A	text	0.80	0.13	0.06	0.01	朝右侧	0.80	0.13
none		0.64	0.33	0.03	0.01	朝右侧	0.64	0.33
true		0.75	0.24	0.01	0.00	朝右侧	0.75	0.24
twin		0.36	0.62	0.02	0.00	朝左侧	0.36	0.62
decoy		0.44	0.52	0.03	0.01	朝左侧	0.44	0.52
irr		0.57	0.39	0.03	0.01	朝右侧	0.57	0.39
B	text	0.80	0.13	0.06	0.01	朝右侧	0.13	0.80
none		0.65	0.31	0.03	0.01	朝右侧	0.31	0.65
true		0.35	0.63	0.02	0.00	朝左侧	0.63	0.35
twin		0.75	0.24	0.01	0.00	朝右侧	0.24	0.75
decoy		0.38	0.59	0.03	0.01	朝左侧	0.59	0.38
irr		0.56	0.40	0.03	0.01	朝右侧	0.40	0.56



5. 模型的推理过程（中文，逐轮原文）

每个李生两段：无工具直接推理（只给 8 帧粗采样，先在 think 里推理再作答）和带工具的主动推理（zoom + seek，每轮显示 think 全文 → 工具调用 → 返回的帧 → 答案）。生成在 `</tool_call>` 处截停，掐掉了 DeepEyes 的 "addCriterion" 退化输出。看三件事：首轮 think 是否先下结论；zoom/seek 的位置有没有落到 E*；拿到返回图之后第二轮 think 有没有真的据图改判。

无工具直接推理 · s1_occlusion_color 李生 A

问题：画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。这个圆形物体是什么颜色？

A. 红色 B. 蓝色 C. 绿色 D. 黄色

思考 (think)

根据描述，画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。由于卡片是深色的，而物体在卡片滑开的一瞬间露了出来，说明物体的颜色与卡片的颜色不同。在选项中，红色、蓝色、绿色和黄色中，只有黄色与深色卡片的颜色不同。因此，可以推断这个圆形物体是黄色的。

答案：A（红色） → 正确（正确答案 A，红色）

带工具的主动推理 · s1_occlusion_color 李生 A

问题：画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。这个圆形物体是什么颜色？


A. 红色 B. 蓝色 C. 绿色 D. 黄色

第 1 轮 · 思考 (think)

根据描述，这个圆形物体在视频的第3帧中短暂地露了出来。我需要查看第3帧中左下方台面上的圆形物体的颜色。由于圆形物体在大部分时间被深色卡片盖着，只有很短的一瞬露了出来，所以我需要使用 image_zoom_in_tool 工具来放大第3帧中左下方的区域，以便更清晰地看到圆形物体的颜色。

工具调用：image_zoom_in_tool {"frame_index": 3, "bbox_2d": [50, 230, 120, 290], "label": "小圆形物体"} → 返回 1 帧：

[第8帧, t=7.7s, 放大自第3帧 (小圆



第 2 轮 · 思考 (think)

从放大后的画面中可以看到，小圆形物体的颜色是红色。因此，这个圆形物体的颜色是红色。

答案：A (红色) → 正确 (正确答案 A, 红色) | 轮数 2, 工具调用 1 次 (成功 1), 首轮 think 里先下结论再调工具：否

无工具直接推理 · s1_occlusion_color 孪生 B

问题：画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。这个圆形物体是什么颜色？

A. 红色 B. 蓝色 C. 绿色 D. 黄色

思考 (think)

根据描述，画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。由于卡片是深色的，而物体在卡片滑开的一瞬间露了出来，说明物体的颜色与卡片的颜色不同。在选项中，红色、蓝色、绿色和黄色中，只有黄色与深色卡片的颜色不同。因此，可以推断这个圆形物体是黄色的。

答案：A (红色) → 错误 (正确答案 B, 蓝色)

带工具的主动推理 · s1_occlusion_color 孪生 B

问题：画面左下方的台面上有一个小圆形物体，视频里大部分时间它都被一张深色卡片盖着，只有很短的一瞬卡片滑开、物体露了出来。这个圆形物体是什么颜色？


A. 红色 B. 蓝色 C. 绿色 D. 黄色

第 1 轮 · 思考 (think)

根据描述，这个圆形物体在视频中大部分时间被深色卡片盖着，只有很短的一瞬卡片滑开，物体露了出来。我们需要查看第3帧，因为在这个帧中，卡片滑开，露出了这个圆形物体。然后，我们可以通过放大这个区域来确认物体的颜色。

工具调用：image_zoom_in_tool {"frame_index": 3, "bbox_2d": [50, 229, 126, 305], "label": "小圆形物体"} → 返回 1 帧：

[第8帧, t=7.7s, 放大自第3帧 (小圆



第 2 轮 · 思考 (think)

通过放大第3帧的小圆形物体区域，我们可以看到这个圆形物体的颜色是红色。

答案：A (红色) → 错误 (正确答案 B, 蓝色) | 轮数 2, 工具调用 1 次 (成功 1), 首轮 think 里先下结论再调工具：否

无工具直接推理 · s2_tiny_tag 孪生 A

问题：画面右下方的吧台上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

思考 (think)

图片中显示的是一个酒吧场景，画面右下方的吧台上确实有一张白色小标签，标签上印着一个数字。通过仔细观察，可以确认标签上的数字是356。

答案：B (356) → 错误 (正确答案 A, 358)

带工具的主动推理 · s2_tiny_tag 孪生 A

问题：画面右下方的吧台上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

第 1 轮 · 思考 (think)

为了看清吧台上白色小标签上的数字，我需要放大该区域。根据描述，标签位于画面右下方的吧台上。我将使用image_zoom_in_tool函数来放大这一区域。

工具调用：image_zoom_in_tool {"frame_index": 7, "bbox_2d": [500, 330, 530, 360], "label": "白色小标签"}
→ 返回 1 帧：

[第8帧, t=4.0s, 放大自第7帧 (白色



第 2 轮 · 思考 (think)

通过放大后的画面，可以清晰地看到吧台上白色小标签上的数字是356。因此，正确答案是B。

答案：B (356) → 错误 (正确答案 A, 358) | 轮数 2, 工具调用 1 次 (成功 1), 首轮 think 里先下结论再调工具：否

无工具直接推理 · s2_tiny_tag 孪生 B

问题：画面右下方的吧台上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

思考 (think)

图片中显示的是一个酒吧场景，画面右下方的吧台上确实有一张白色小标签，标签上印着一个数字。通过仔

细观察，可以确认标签上的数字是356。

答案：B (356) → 错误 (正确答案 D, 386)

带工具的主动推理 · s2_tiny_tag 孪生 B

问题：画面右下方的吧台上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

第 1 轮 · 思考 (think)

为了确定吧台上白色小标签上的数字，我需要放大该区域进行查看。根据描述，这个标签位于画面右下方的吧台上。我将使用image_zoom_in_tool函数来放大这一区域。

工具调用：image_zoom_in_tool {"frame_index": 7, "bbox_2d": [500, 330, 530, 360], "label": "白色小标签"}
→ 返回 1 帧：

[第8帧, t=4.0s, 放大自第7帧 (白色



第 2 轮 · 思考 (think)

通过放大第7帧的右下方吧台区域，我们可以清晰地看到白色小标签上的数字是356。因此，正确答案是B。

答案：B (356) → 错误 (正确答案 D, 386) | 轮数 2，工具调用 1 次 (成功 1)，首轮 think 里先下结论再调工具：否

无工具直接推理 · s2b_tiny_tag_1080p 孪生 A

问题：画面底部中央的台面上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

思考 (think)

图片中显示的标签位于画面底部中央的台面上，标签上印着一个数字。通过观察图片，可以看到标签上的数字是356。因此，标签上印的数字是356。

答案：B (356) → 错误 (正确答案 A, 358)

带工具的主动推理 · s2b_tiny_tag_1080p 孪生 A

问题：画面底部中央的台面上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

第 1 轮 · 思考 (think)

为了确定标签上的数字，我需要放大画面底部中央的台面上的白色小标签。这可以通过使用image_zoom_in_tool函数来实现。

工具调用：image_zoom_in_tool {"frame_index": 7, "bbox_2d": [280, 320, 350, 360], "label": "白色小标签"}
→ 返回 1 帧：

[第8帧, t=18.0s, 放大自第7帧 (白色



第 2 轮 · 思考 (think)

通过放大后的画面，可以清晰地看到白色小标签上的数字是356。因此，标签上印的数字是356。

答案：B (356) → 错误 (正确答案 A, 358) | 轮数 2，工具调用 1 次 (成功 1)，首轮 think 里先下结论再调工具：否

无工具直接推理 · s2b_tiny_tag_1080p 孪生 B

问题：画面底部中央的台面上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

思考 (think)

图片中显示的标签位于画面底部中央的台面上，标签上印着一个数字。通过观察图片，可以看到标签上的数字是356。因此，标签上印的数字是356。

答案：B (356) → 错误 (正确答案 D，386)

带工具的主动推理 · s2b_tiny_tag_1080p 孪生 B

问题：画面底部中央的台面上放着一张白色小标签，上面印着一个数字。标签上印的数字是多少？

A. 358 B. 356 C. 338 D. 386

第 1 轮 · 思考 (think)

为了确定标签上的数字，我需要放大画面底部中央的台面上的白色小标签。这可以通过使用 image_zoom_in_tool 函数来实现。

工具调用：image_zoom_in_tool {"frame_index": 7, "bbox_2d": [220, 320, 300, 360], "label": "白色小标签"}
→ 返回 1 帧：

[第8帧, t=18.0s, 放大自第7帧 (白色小标签)]



第 2 轮 · 思考 (think)

通过放大后的画面，可以清晰地看到白色小标签上的数字是356。因此，标签上印的数字是356。

答案：B (356) → 错误 (正确答案 D，386) | 轮数 2，工具调用 1 次 (成功 1)，首轮 think 里先下结论再调工具：否

无工具直接推理 · s3b_flash_symbol 孪生 A

问题：视频中有一瞬间，画面右下方的桌面上出现一张印着黑色图案的白色卡片。卡片上的图案是什么？

A. 三角形 B. 正方形 C. 圆形 D. 十字

思考 (think)

根据描述，视频中有一瞬间，画面右下方的桌面上出现了一张印着黑色图案的白色卡片。由于描述中提到的是“印着黑色图案”，并且选项中只有圆形可以印制图案，因此可以推断卡片上的图案是圆形。

答案：C (圆形) → 错误 (正确答案 A，三角形)

带工具的主动推理 · s3b_flash_symbol 孪生 A

问题：视频中有一瞬间，画面右下方的桌面上出现一张印着黑色图案的白色卡片。卡片上的图案是什么？

A. 三角形 B. 正方形 C. 圆形 D. 十字

第 1 轮 · 思考 (think)

根据描述，我们需要查看第6帧，因为问题是关于第6帧画面右下方的桌面上出现的卡片。我们需要使用 image_zoom_in_tool 来放大这一区域，以便更清晰地看到卡片上的图案。

工具调用：image_zoom_in_tool {"frame_index": 6, "bbox_2d": [450, 190, 587, 280], "label": "卡片"} → 返回 1 帧：

[第8帧, t=7.7s, 放大自第6帧 (卡片)]



第 2 轮 · 思考 (think)

通过放大第6帧的右下方区域，我们可以看到卡片上的图案是一个圆形。因此，正确答案是C. 圆形。

答案：C (圆形) → 错误 (正确答案 A, 三角形) | 轮数 2, 工具调用 1 次 (成功 1), 首轮 think 里先下结论再调工具：否

无工具直接推理 · s3b_flash_symbol 孪生 B

问题：视频中有一瞬间，画面右下方的桌面上出现一张印着黑色图案的白色卡片。卡片上的图案是什么？

A. 三角形 B. 正方形 C. 圆形 D. 十字

思考 (think)

根据描述，视频中有一瞬间，画面右下方的桌面上出现了一张印着黑色图案的白色卡片。由于描述中提到的是“印着黑色图案”，并且选项中只有圆形可以印制图案，因此可以推断卡片上的图案是圆形。

答案：C (圆形) → 正确 (正确答案 C, 圆形)

带工具的主动推理 · s3b_flash_symbol 孪生 B

问题：视频中有一瞬间，画面右下方的桌面上出现一张印着黑色图案的白色卡片。卡片上的图案是什么？

A. 三角形 B. 正方形 C. 圆形 D. 十字

第 1 轮 · 思考 (think)

根据描述，我们需要查看第6帧，因为问题是关于第6帧画面右下方的桌面上出现的卡片。我们需要使用 image_zoom_in_tool 工具来放大这一区域，以便更清晰地看到卡片上的图案。

工具调用：image_zoom_in_tool {"frame_index": 6, "bbox_2d": [450, 250, 588, 336], "label": "卡片"} → 返回 1 帧：

[第8帧, t=7.7s, 放大自第6帧 (卡片



第 2 轮 · 思考 (think)

通过放大第6帧的右下方区域，我们可以看到桌面上有一张印着黑色图案的白色卡片。卡片上的图案看起来像是一个十字形。

答案：D (十字) → 错误 (正确答案 C, 圆形) | 轮数 2, 工具调用 1 次 (成功 1), 首轮 think 里先下结论再调工具：否

无工具直接推理 · s3_roll_direction 孪生 A

问题：视频中有一瞬间，一个橙色小球从画面底部的桌面上滚过。随着时间推移，小球朝画面的哪一侧运动？

A. 朝右侧 B. 朝左侧 C. 朝上方 D. 朝下方

思考 (think)

根据描述，视频中有一个橙色小球从画面底部的桌面上滚过。在第6帧和第7帧中，可以看到小球的位置发生了变化，从第6帧的右侧边缘移动到了第7帧的左侧边缘。因此，小球是从画面的右侧向左侧运动的。

答案：B (朝左侧) → 错误 (正确答案 A, 朝右侧)

带工具的主动推理 · s3_roll_direction 孪生 A

问题：视频中有一瞬间，一个橙色小球从画面底部的桌面上滚过。随着时间推移，小球朝画面的哪一侧运动？

A. 朝右侧 B. 朝左侧 C. 朝上方 D. 朝下方

第 1 轮 · 思考 (think)

根据描述，小球从画面底部的桌面上滚过，随着时间推移，小球朝画面的哪一侧运动。我们需要查看视频中是否有小球从画面底部滚过，并观察其运动方向。由于视频帧的顺序是从0.0s到9.0s，我们可以使用 video_seek_tool 来密集回看这一时间段，以更清晰地观察小球的运动方向。

工具调用：video_seek_tool {"start_time": 7.7, "end_time": 8.0, "num_frames": 3} → 返回 3 帧：



第 2 轮 · 思考 (think)

通过密集回看，我们可以清晰地看到一个小球从画面底部滚过。根据小球的运动轨迹，它从画面的左侧滚向右侧。因此，小球朝画面的右侧运动。

答案：A（朝右侧） → 正确（正确答案 A，朝右侧） | 轮数 2，工具调用 1 次（成功 1），首轮 think 里先下结论再调工具：否

无工具直接推理 · s3_roll_direction 孪生 B

问题：视频中有一瞬间，一个橙色小球从画面底部的桌面上滚过。随着时间推移，小球朝画面的哪一侧运动？

A. 朝右侧 B. 朝左侧 C. 朝上方 D. 朝下方

思考 (think)

根据描述，视频中有一个橙色小球从画面底部的桌面上滚过。在第6帧和第7帧中可以看到这个小球，它位于画面的右侧边缘。随着时间推移，小球从画面的右侧滚向左侧，最终消失在画面中。因此，小球的运动方向是从右侧向左侧。

答案：B（朝左侧） → 正确（正确答案 B，朝左侧）

带工具的主动推理 · s3_roll_direction 孪生 B

问题：视频中有一瞬间，一个橙色小球从画面底部的桌面上滚过。随着时间推移，小球朝画面的哪一侧运动？

A. 朝右侧 B. 朝左侧 C. 朝上方 D. 朝下方

第 1 轮 · 思考 (think)

根据描述，小球从画面底部的桌面上滚过，随着时间推移，小球朝画面的哪一侧运动。我们需要查看视频中是否有小球从画面底部滚过，并观察其运动方向。由于视频帧的顺序是从0.0s到9.0s，我们可以使用 video_seek_tool 来密集回看小球滚过的时间段，即从0.0s到1.3s。

工具调用：video_seek_tool {"start_time": 0.0, "end_time": 1.3, "num_frames": 6} → 返回 6 帧：



第 2 轮 · 思考 (think)

通过密集回放的视频帧，我们可以看到小球从画面底部滚过，并且在第13帧中，小球已经滚出了画面。根据这些帧，小球是从画面的左侧滚向右侧的。

答案：A（朝右侧） → 错误（正确答案 B，朝左侧） | 轮数 2，工具调用 1 次（成功 1），首轮 think 里先下结论再调工具：否

6. 发现与下一步

- Necessity 可以由样本客观定义并被机器认证：五条样本在中英文下 C1-C4 全过；认证流程（四条件 + 信念 + 配对平均判据）已经是可复用的代码。

- Utilization 可测且拉得开：同一前缀上 true / twin / decoy / irr 四个条件给出截然不同的信念，这就是方案里 EEG 与四种 resolution 模式的数据来源。
- DeepEyes 在这批样本上的三层失败：时间定位不到窗口（s1-B seek 到 17.8–18.2s，真窗口 10.9–12.2s；s3-B seek 到 0–1.3s，真窗口 5.3–6.2s）；空间定位不到标签（s2/s2b 四条 zoom 全没框到）；拿到证据也被先验压住（s3 粗采样里没有球，think 却写“在第6帧和第7帧中可以看到这个小球”）。
- DeepEyes 的分辨率阈值：粗采样帧上 ~5.5px 数字能读、~4px 读不出、原生 9–12px 裁剪 100% 读对——空间 necessity 能落脚的窗口比预想的窄。
- 边界：这 5 条是真实视频上的受控合成编辑（来源 B），用来跑通流程；论文主体要靠 VideoNet 自然孪生对（来源 A，用 domain_name + definition + start/end 挖同域易混类），先做 50 对走一遍 C1–C4 看通过率。

附：文件清单

路径（data/evidencegap_v_pilot/）	内容
make_samples.py	生成器，参数全在 PARAMS，每次迭代升 --version
samples.json / videos/	题面（中英）、孪生答案、E* 时间窗与空间框、decoy 定义；5 对孪生视频
eval_deepeyes.py	认证器（--lang zh/en，--no-agentic）
evidencegap_pilot.ipynb / build_notebook.py / pilot_viz.py	可运行的验证 notebook（骨架 / 生成脚本 / 展示层）；*_executed.ipynb 为已跑版本
eval/results_final.json, results_notebook.json, check_final.jpg	英文定版结果、中文 notebook 结果、最终检查图
README.md	设计、判据、结果、四轮迭代记录